

Komunikacija človek računalnik

Druga seminarska naloga

Izločanje očesnih artefaktov z uporabo postopka analize neodvisnih komponent

Nace Gorenc

Januar 2021

1 Uvod

Filtriranje signalov je pomemben del pri procesiranju signalov EEG med interakcijo možgani računalnik. V EEG signalih lahko pride do šuma zaradi premikanja mišic na lobanji. Čiščenje teh šumov je ključnega pomena za nadaljno uporabo signalov, saj pripomore k boljšim rezultatom pri učenju komunikacije. V tej seminarski nalogi se bomo osredotočili na izločanje očesnih artefaktov, do katerih pride zaradi utripanja oči. Pogledali si bomo postopek analize neodvisnih komponent ter njegovo implementacijo na realnih podatkih.

2 Metode

Analiza neodvisnih komponent (ANK) spada med prostorske filtre. Prostorski filtri transformirajo N -kanalni signal $X(n)$ v signal $Y(n)$, $n = 1, \dots, N$. Dobimo jih z enačbo

$$Y(n) = W \cdot X(n),$$

pri čemer je W neka transformacijska matrika, ki slika prostor signalov v prostor komponent. Originalne signale filtriramo tako, da predelamo matriko W v matriko W' in izračunamo

$$\tilde{X}(n) = (W')^{-1} \cdot Y(n)$$

2.1 Metoda ANK

Pri metodi ANK se s filtriranjem skušamo čim bolj približati izvornim signalom. Metoda ANK naredi dekompozicijo signalov v statistično neodvisne komponente. Predpostavimo, da je možganski signal $S(n)$ sestavljen iz N medsebojno

neodvisnih izvornih neznanih virov ter da imamo N merjenih signalov $X(n)$, ki so rezultati sprotnega linearne mešanja signalov $S(n)$. Velja

$$X(n) = A \cdot S(n),$$

kjer je A časovno invariantna mešalna matrika velikosti $N \times N$, katere elementi so ocenjeni preko merjenih signalov $X(n)$.

ANK dekompozicijo lahko naredimo tedaj, ko:

1. so $S(n)$ medseboj neodvisni,
2. $S(n)$ niso distribuirani po Gauss-u,
3. je število neodvisnih komponent enako številu snemalnih signalov.

Če veljajo zgornje točke, lahko aproksimiramo neko matriko W in mešalno matriko A , da velja

$$A \approx W^{-1}.$$

Matriko W izračunamo z metodo kanonične korelacijske analize. Z izračunom

$$Y(n) = W \cdot X(n) = W \cdot A \cdot S(n) \approx S(n)$$

dobimo, da je $Y(n)$ približek izvornemu signalu $S(n)$. Torej metoda skuša dobiti izvirne signale ob predpostavki, da so izvorni signali statistično neodvisni.

V nadaljevanju izberemo P signalov v prostoru komponent, za katere se odločimo, da ne predstavljajo šuma. Sestavimo matriko Y dimenzije $P \times M$, katere vrstice predstavljajo signale v prostoru komponent. Signale lahko izbiramo po lastni presoji, lahko pa si pomagamo s topografsko distribucijo stolpcev matrike W^{-1} . Za vsako stolpec matrike W^{-1} izrišemo topografske distribucije in se na podlagi slik odločimo, katerih stolpcev matrike se bomo znebili, hkrati pa se znebimo tudi istoležnih vrstic matrike Y dimenzije $N \times M$. Dobimo novi matriki \tilde{W} dimenzije $N \times M$ in \tilde{Y} dimenzije $N \times P$, da velja

$$\tilde{X}(n) = \tilde{W}^{-1} \times \tilde{Y}(n),$$

kjer je $\tilde{X}(n)$ očiščen signal.

3 Rezultati

V tem poglavju si bomo najprej pogledali, kako pridemo do danih rezultatov, potem pa jih bomo tudi predstavili.

3.1 Algoritem

Najprej izvozimo EEG signale. Izberemo si prvi posnetek osebe številka 10, na katerem je oseba mirovala in imela odprte oči.

```
[X, freq, tm] = rdsamp('S010R01.edf');
```

Izračunamo matrike Y (neodvisne komponente), A (mešalna matrika) in W .

```
[Y, A, W] = fastica(eeg(:, 1:64)');
```

Izračunamo inverz matrike W (v nadaljevanju ga označimo z W_1) in za vsak stolpec inverza izrišemo topografsko distribucijo s pomočjo funkcije *plot_topography*, ki za argumente sprejme seznam imen kanalov ter vrednosti na posameznih kanalih.

```
for i = 1:size(W1, 1)
    figure;
    plot_topography(ch_list, W1(:, i));
end
```

Pregledamo vse slike in si zabeležimo tiste, pri katerih opazimo aktivnost čelnega dela glave, saj nakazujejo na šum. Na koncu zberemo pripadajoče stolpce matrike W_1 in vrstice matrike Y , ter izračunamo novo matriko \tilde{X} .

3.2 Predstavitev rezultatov

Slika 1 prikazuje signale na elektrodah pred filtriranjem šumov. Opazimo lahko, da se pri nekaterih signalih pojavljajo bliskoviti skoki in padci na istih mestih. Predpostavljamo, da ta nihanja krivulje predstavljajo mežikanje.

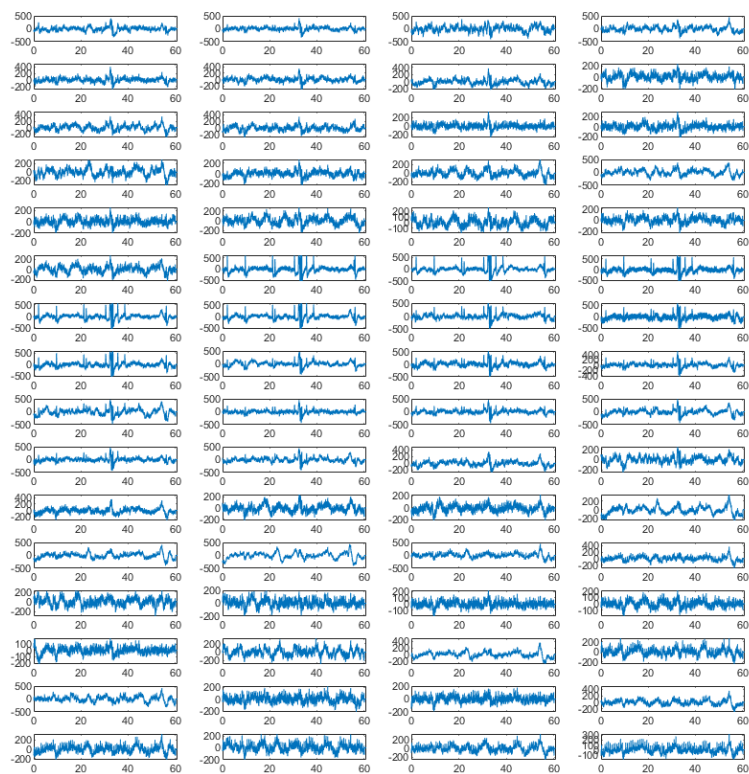
Signali v prostoru komponent so prikazani na sliki 2. Opazimo, da skoraj vsak graf komponente vsebuje vsaj en očiten globalni maksimum ali minimum. Iz teh grafov ne moremo neposredno določiti, katere komponente predstavljajo mežikanje z očmi.

Slika 3 prikazuje topografske distribucije stolpcev matrike W_1 , katere odstranimo. Pri tem odstranimo tako stolpce, ki kažejo na povišanje aktivnosti sprednjega dela glave, kot tiste, ki nakazujejo na nižanje.

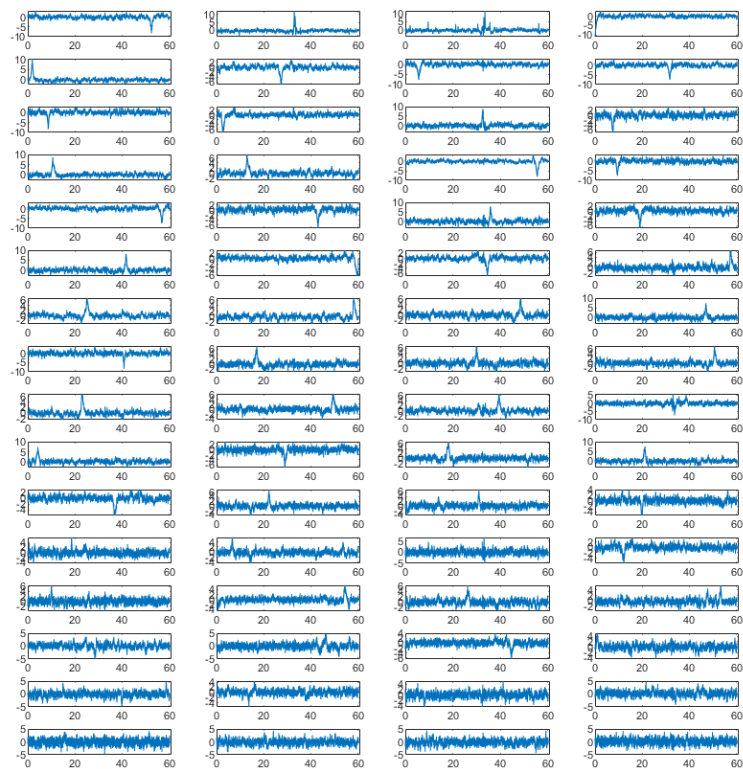
Slika 4 prikazuje signale elektrod po filtriranju šumov. Primerjava grafov te slike in slike 1 nam pove, da smo uspešno odstranili šum, ki ga je povzročilo mežikanje oči. Podrobnejši prikaz lahko vidimo na sliki 5, ki prikazuje signal elektrode Fpz, ki je frontalna sredinska. Opazimo lahko, da je oseba na tem posnetku pomežiknila desetkrat.

4 Zaključek


Metoda ANK je bila pri danem posnetku uspešna, saj smo uspešno izločili očesne artefakte. Nalogo bi lahko nadgradili z bolj podrobno analizo izločanja stolpcev matrike W_1 , in sicer tako, da bi primerjali razliko vrednosti novih signalov pri različnih kombinacijah izločenih stolpcev. Dodatno bi lahko izločili tudi ušesne artefakte.




Slika 1: Osnovni signali.




Slika 2: Signali v prostoru komponent.




(a) Stolpec 2




(b) Stolpec 3




(c) Stolpec 10




(d) Stolpec 19



(e) Stolpec 23

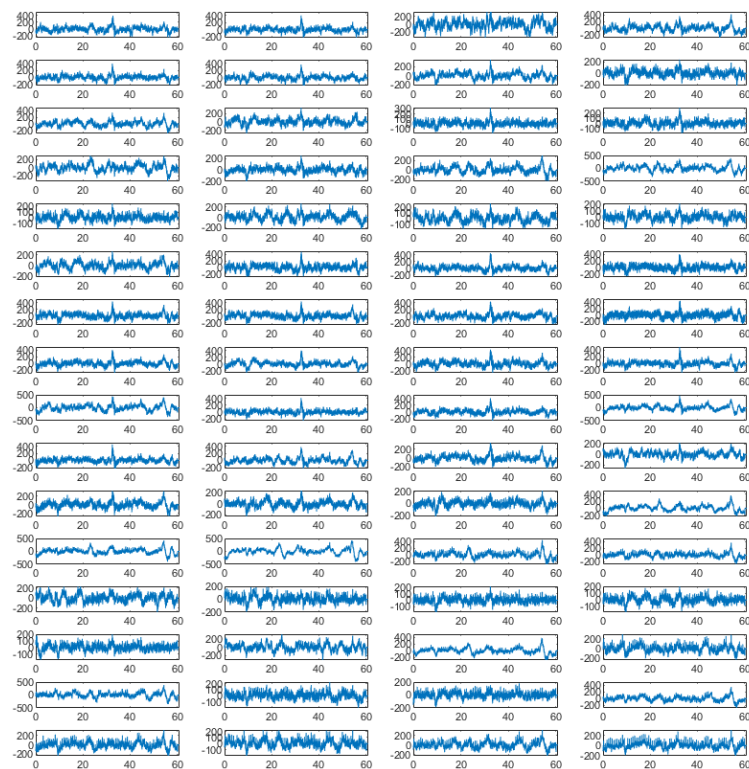


(f) Stolpec 35




(g) Stolpec 36

Slika 3: Pregled stolpcev matrike W_1 , ki jih izločimo.



Slika 4: Korigirani signali.



Slika 5: Primerjava signala iz elektrode Fpz (frontalna sredinska) pred in po filtriranju.